Propuesta de proyecto

1. Datos del equipo

- **Integrantes:**

Nombre	Correo
Geer Wang Liu	geer.wang@estudiante.uam.es
Zhenhua Ye Xiang	zhenhua.ye@estudiante.uam.es
Linda Fei Payeras Olano	linda.payeras@estudiante.uam.es

- **Dimensiones abordadas:** Transparencia algorítmica
- **Modalidad de los datos:** Imagen
- **Entrega**: Inicial

2. Pregunta de investigación y objetivo

Dos modelos pueden producir una misma etiqueta, sin embargo, no quiere decir que se basen en la misma evidencia visual de imágenes. Mientras que uno usa texturas otro puede fijarse en la distribución de diferentes objetos a pesar de predecir la misma salida. Esta situación da lugar a la pregunta: “hasta qué punto las regiones que destacan sus explicaciones son similares y cuánto depende esta similitud del método de explicabilidad utilizado?”

El objetivo principal es comparar las explicaciones de dos modelos preentrenados, ResNet50 y EfficientNet-B0, sobre las mismas imágenes, evaluar la similitud y fiabilidad de las explicaciones. Planteando la hipótesis que los mapas de atribución no serán equivalentes ante la misma situación. Además el grado de coincidencia dependerá del método utilizado. El proyecto está relacionado con la asignatura al usarse métodos basados en gradientes, la atribución de características y la evaluación de la consistencia entre explicaciones de distintos modelos, la fidelidad, la estabilidad y la sensibilidad a la aleatorización de los pesos.

3. Componentes del proyecto

Modelos preentrenados. Se utilizarán ResNet50 (pesos IMAGENET1K_V2) y EfficientNet-B0 (pesos IMAGENET1K_V1), disponibles en Torchvision [1] y preentrenados con ImageNet-1K. No se realizará entrenamiento ni ajuste adicional. Se fijarán las versiones de los pesos y las bibliotecas para garantizar la reproducibilidad.

Conjunto de datos. Se utilizará Imagenette v2 (320 px), subconjunto de diez categorías de ImageNet con 13.394 imágenes. Se seleccionarán 300 imágenes de validación, 30 por categoría, para mantener una muestra equilibrada. Se comprobarán las condiciones de uso de las imágenes originales y no se incluirá el dataset en el repositorio del proyecto.

Técnicas de explicabilidad. Se usarán dos técnicas *post-hoc* de atribución de características: Grad-CAM [2] e Integrated Gradients [3]. La primera, implementada mediante la biblioteca pytorch-grad-cam, genera un mapa de calor que localiza las regiones más relevantes de la imagen para la predicción. La segunda, implementada con Captum, asigna un valor de importancia a cada píxel de la imagen.

Métricas de evaluación. Se evaluará la similitud mediante Spearman y el solapamiento del 20% de píxeles más relevantes. La fidelidad mediante curvas *deletion/insertion* y sus AUC. Además de la estabilidad mediante la similitud de mapas ante transformaciones leves que preserven la predicción. Se realizarán pruebas de aleatorización de pesos para evaluar la sensibilidad de las explicaciones a los parámetros aprendidos [6]. Se considerará Quantus [4] como apoyo para calcular las métricas.

Transparencia y marco regulatorio. Se tomará como referencia el Reglamento (UE) 2024/1689 [7], especialmente los artículos 2.6 y 2.8 (investigación), 13 (transparencia de sistemas de alto riesgo) y 50 (obligaciones específicas de transparencia). Se utilizará el artículo 13 como referencia para analizar la interpretabilidad y las limitaciones de los modelos. El estudio requiere acceso a los pesos, gradientes y activaciones internas (*open-box*), disponibles mediante PyTorch, pero no a los datos originales de entrenamiento.

4. Diseño experimental

El estudio seguirá un diseño comparativo basado en la generación y evaluación de explicaciones para ambos modelos.

Procedimiento experimental

1. **Preparación**: seleccionar 300 imágenes de validación de Imagenette, fijar semilla y registrar sus identificadores. Aplicar cada modelo su preprocesamiento correspondiente
2. **Inferencia**: ejecutar ambos modelos y registrar logits, top-1, top-5 y confianza. Calcular la *accuracy* y la tasa de acuerdo.
3. **Similitud**: aplicar las dos técnicas de explicabilidad mencionadas, normalizar los mapas y calcular las métricas de similitud.
4. **Fiabilidad**: aplicar *deletion/insertion* para comprobar si las regiones atribuidas por cada explicación son realmente relevantes para la predicción de cada modelo.
5. **Estabilidad:** aplicar transformaciones leves que preserven la predicción y comparar los mapas de atribución originales con los obtenidos tras las transformaciones. Se realizará también una

prueba de aleatorización progresiva de pesos para comprobar la sensibilidad de las explicaciones a los parámetros aprendidos.

6. **Impacto**: medir tiempo y energía estimada por etapa con CodeCarbon, registrando hardware, duración, tamaño de muestra, versiones y emisiones estimadas.

5. Alcance, limitaciones y riesgos

- **Incluido:** comparación de las explicaciones de ResNet50 y EfficientNet-B0 mediante Grad-CAM e Integrated Gradients en Imagenette; evaluación de similitud, fidelidad y estabilidad; registro del consumo de recursos.
- **Fuera del alcance:** entrenar o ajustar modelos, analizar todo ImageNet, evaluar la comprensión de las explicaciones por parte de los usuarios o demostrar que los modelos siguen el mismo razonamiento interno.

Limitación o riesgo	Medida prevista
Acceso y condiciones de Imagenette: las imágenes pueden tener restricciones.	Comprobar la disponibilidad y las condiciones de uso de las imágenes.
Preprocesamiento diferente: distintos recortes pueden afectar a la comparación.	Documentar las transformaciones y asegurar que los mapas comparados correspondan al mismo contenido visual.
Entrenamiento diferente: los resultados no dependen solo de la arquitectura.	Fijar las versiones utilizadas y no atribuir todas las diferencias únicamente a la arquitectura.
Mapas diferentes: las técnicas tienen distinta resolución y significado.	Usar la misma clase objetivo, ajustar la resolución y documentar la normalización; comparar cada método por separado.
Recursos limitados: las pruebas pueden requerir demasiado tiempo o memoria.	Utilizar lotes pequeños y reducir el número de imágenes en las pruebas costosas.
Interpretación excesiva: mapas similares no implican el mismo razonamiento.	Contrastar la similitud con las pruebas de fidelidad y estabilidad.

6. Plan de trabajo y reparto de roles

Repartiremos las tareas por fases y revisaremos los resultados entre las tres. Las horas estimadas por persona podrán ajustarse según las dificultades.

Fases / tareas	Responsable	Horas	Periodo
Elaboración de la propuesta inicial	Las tres	4 h/p	8-10 nov.
Preparación de Imagenette, carga de modelos e inferencia inicial	Linda	6 h	11-16 nov.
Implementación de Grad-CAM	Zhenhua	5 h	11-18 nov.
Implementación de Integrated Gradients	Geer	5 h	11-18 nov.
Métricas de similitud y visualización	Zhenhua	4 h	17-21 nov.
Evaluación de fidelidad (deletion/insertion)	Geer	4 h	17-21 nov.

Evaluación de estabilidad y aleatorización	Linda	4 h	17-22 nov.
Medición del impacto computacional con CodeCarbon	Linda	3 h	18-22 nov.
Integración del notebook de viabilidad, pruebas y propuesta revisada	Las tres	4 h/p	20-24 nov.
Análisis de resultados, documentación y memoria final	Las tres	5 h/p	25 nov.-15 dic.
Preparación de presentación y defensa	Las tres	3 h/p	16-18 dic.

7. Referencias iniciales

- [1] Torchvision, documentación de modelos y pesos preentrenados: https://docs.pytorch.org/vision/main/models.html
- [2] Selvaraju et al. (2017), "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization", ICCV: https://openaccess.thecvf.com/content_iccv_2017/html/Selvaraju_Grad-CAM_Visual_Explanations_ICCV_2017_paper.html
- [3] Sundararajan, Taly y Yan (2017), "Axiomatic Attribution for Deep Networks", ICML: https://proceedings.mlr.press/v70/sundararajan17a.html
- [4] Quantus, biblioteca para la evaluación de explicaciones de redes neuronales: https://github.com/understandable-machine-intelligence-lab/Quantus
- [5] Howard, J. Imagenette. Fast.ai. https://github.com/fastai/imagenette?utm_source=chatgpt.com
- [6] Adebayo, J., et al. (2018). Sanity Checks for Saliency Maps. NeurIPS. https://proceedings.neurips.cc/paper_files/paper/2018/file/294a8ed24b1ad22ec2e7efea049b8737-Paper.pdf
- [7] Parlamento Europeo y Consejo de la Unión Europea (2024). Reglamento (UE) 2024/1689, versión consolidada vigente. https://eur-lex.europa.eu/legal-content/EN/ALL/?uri=CELEX:32024R1689&utm_source=chatgpt.com

8. Uso de asistentes de IA

Se han utilizado ChatGPT, DeepSeek y Claude para explorar ideas, organizar y mejorar la propuesta, comprender contenidos y resolver dudas. Prevemos mantener estos usos durante el proyecto, revisando sus respuestas y contrastándolas con los materiales de clase y las fuentes originales. La pregunta de investigación, el diseño experimental, la interpretación de resultados y las conclusiones serán trabajo propio del equipo.